# HW 1 Rezitdinov

1 FLOPS = 0.5 MAC

Linear = 1 FLOP/вых
BN = ax + b = 2 FLOP/эл
RELU = 1 FLOP/эл
MaxPool =
GAP =

**Bytes Moved** Q - каждый слой ч/з DRAM 1 раз (нет переисп м/у слоями)

**Latency** - median для 1 forward pass

**Energy** - энергия всей платы за 1 forward (мДж) / число прогонов

| Слой | Выход | Эл-в |
|---|---|---|
| Вход | $3 \times S \times S$ | $3S^2$ |
| Conv1 7x7s2 | $32 \times S/2 \times S/2$ | $8S^2$ |
| Maxpool | $32 \times S/4 \times S/4$ | $2S^2$ |
| Conv2 5x5 | $64 \times S/4$ | $4S^2$ |
| Conv3 3x3 s2 | $128 \times S/8$ | $2S^2$ |
| Conv4 1x1 | $256 \times S/8$ | $4S^2$ |
| Conv5 3x3s2 | $256 \times S/16$ | $S^2$ |
| Conv6 1x1 | $512 \times S/16$ | $2S^2$ |
| GAP/fc1/fc2 | 512/256/100 | const |

Date No.

FLOPs

Conv: $MAC = B \cdot H_{out} W_{out} \cdot C_{out} \cdot C_{in} k^2$

| Слой | $C_{in} k^2$ | Выход/изоб | MAC/изоб |
|---|---|---|---|
| conv1 | $3 \cdot 49 = 147$ | $8S^2$ | $1176S^2$ |
| conv2 | $32 \cdot 25 = 800$ | $4S^2$ | $3200S^2$ |
| conv3 | $64 \cdot 9 = 576$ | $2S^2$ | $1152S^2$ |
| conv4 | 128 | $4S^2$ | $512S^2$ |
| conv5 | 2304 | $S^2$ | $2304S^2$ |
| conv6 | 256 | $2S^2$ | $512S^2$ |
| $\Sigma_{conv}$ | | | $8856S^2$ |
| $fc_1, fc_2$ | | | 156672 |

$Conv + Linear = F_{mn}(S, B) = 2B \cdot (8856S^2 + 156672) =$
$= B(17712S^2 + 3'13344)$

Elem-t wise ops $= 8 + 4 + 2 + 4 + 1 + 2 = 21S^2$ — выходы всех conv

$BN = 2 \cdot 21S^2 = 42S^2$

$ReLU = 21S^2 + 256$

$MaxPool = 8 \cdot 2S^2 = 16S^2$

$GAP = 2S^2 + 512$

bias fc $= 256 + 100 = 356$

Пар-ры

conv 21-B

BN 883 296

4992

FC 157 028

$\Sigma$ 1045 316 ~ (4,18 МБ)

$M_w = 4 \cdot 1045316 = 4\,181\,264$ Б, (вкл. tensor до 512 Б, 6 счетчиков, int64) $M_w^{alloc} \approx 4\,187\,136$ Б)

## Память в пике

ReLU - без аллок.:
MaxPool - доп индексы
2× байт от выхода

| Шаг | Жив. | $\Sigma, S^2$ |
|---|---|---|
| conv1 | x(3)+c1(8) | 11 |
| bn1 | x(3)+c1(8)+b1(8) | 19 |
| maxpool | x(3)+b1(8)+p(2)+idx(4) | 17 |
| conv2/bn2 | 3+2+4/3+4+4 | 9/11 |
| conv3/bn3 | 3+4+2/3+2+2 | 9/7 |
| conv4/bn4 | 3+2+4/3+4+4 | 9/11 |
| conv5 ~~/~~bn6 ... | ≤8 | ≤8 |

$Memory(S,B) = M_w^{alloc} + M_{ws} + 76BS^2$ (пик на bn1)

$M_w^{alloc} = 4\,187\,136$ Б

$M_{ws} = 9\,568\,256$ Б

Максимум на сетке: $S = 512$, $B = 256$.
$76 \cdot 512^2 \cdot 256 \approx$ ~~5,1 ГБ~~ $\approx 5{,}11$ ГБ ~~$~~ < 15.6 ГБ на T4

Граница OOM: $BS^2 \lesssim 15 \cdot 10^9 / 76 \approx 2 \cdot 10^8$ ($S=512$, $B \approx 750$)

## ~~Byte~~ Bytes moved

$Q_L \approx 4 \cdot (B \times o_g + 56 \times o_g + \Sigma E c_a)$ + int64 ind в pooling

Date No.

| Слой | $Q/(BS^2)$, Б | Веса, Б | AI=FQ при бол |
|---|---|---|---|
| conv1 | 4(3+8)=44 | 18816 | 53 |
| bn1, relu1 | 64, 64 | 512 | 0.25, 0.125 |
| maxpool | 32+8+16=56 | — | 0.29 |
| conv2 | 24 | 204800 | 267 |
| conv3 | 24 | 294912 | 96 |
| conv4 | 24 | 131072 | 43 |
| conv5 | 20 | 2359296 | 230 |
| conv6 | 12 | 524288 | 85 |
| bn/relu 2–6 | 2·(32+16+32+8+16)=208 | 19456 | 0.25/0.125 |
| GAP | 8 | — | 0.25 |

$Q(S,B) = 4\,181\,264 + B(548S^2 + 8592)$ Б

Вся сеть ≈ 32,5 FLOP/Б

Точка перегиба T4 ≈ 25 FLOP/Б

## Latency

$T(S,B;\theta) = t_0 + \sum_{\ell=1}^{23} \mathrm{smax}\left(t_{op}, \frac{F_\ell}{P}, \frac{Q_\ell}{BW}\right)$, $\mathrm{smax}(a,b,c) = (a^6+b^6+c^6)^{1/6}$, $\theta = (t_0, t_{op}, P, BW)$.

smax – глад макс.

Асимптоты:

малые $BS^2$: $T \approx t_0 + 23t_{op} = \mathrm{const}$

большие: $T \approx BS^2\left(\sum_{conv} f_\ell/P + \sum_{elem} q_\ell/BW\right) = BS^2(17712/P + 400/BW)$ – лин. по $BS^2$, ~70% свёр, ~30% memory

переход: $BS^2 \approx (t_0 + 23t_{op})/\left(\sum_{conv} f_\ell/P_\ell + 400/BW\right)$. Откалибр. на T4: $t_0 + 23t_{op} \approx 0.83$ мс

GPU ≈ 5.8 нс на $BS^2$ => $BS^2 \approx 1.4 \cdot 10^5$

При больших $BS^2$ P и BW по e2e latency одинак:

$P = \Sigma F / \Sigma t$ по conv
$BW = \Sigma Q / \Sigma t$ по BN/ReLU, pool
$t_0, t_{op}$ – МНК по $\log T$ на БАЗ. сетке при фикс. P, BW

P и BW одни на все слои ломается:

conv2 ≈ 6,3 TFLOP/s conv3-conv6 ≈ 3,7-4,1 TFLOP/s
conv1 ($C_{in} = 3$, 7×7) ≈ 2,8 TFLOP/s при $B \le 64$ и ≈ 0,65 при $B > 64$. cuDNN меняет алгоритм.

$$T = t_0 + \sum_\ell \operatorname{smax}\left(t_{op}\frac{F_\ell}{P_\ell(B)}, \frac{Q_\ell}{BW}\right), \quad P_{conv1}(B) = \begin{cases} P_1^{lo}, & B \le B^* \\ P_1^{hi}, & B > B^* \end{cases}$$

$P_\ell = \Sigma F_\ell / \Sigma t_\ell$ по GPU всем точкам этого слоя.
$B^* = 64$ м/у 64 и 95 точек нет, т.е. ист порог в $(64, 95]$.

$$\theta = (t_0, t_{op}, BW, P_1^{lo}, P_1^{hi}, P_2, \dots, P_6)$$

## Energy

$$E(S, B; \theta_E) = P_{st} T(S, B; \theta) + e_F \cdot FLOPs(S, B) + e_Q \cdot Q(S, B)$$

$P_{st}$ [Вт] – стат мощн. ГП за все время forward

$e_F$ [Дж/FLOP] – дин. маш. арифм.

$e_Q$ [Дж/Б] – дин. эн-я обмена с DRAM.

Fit: NNLS по относительной ошибке на базовой сетке; в прогнозе T берётся из модели latency.

Огр-я: FLOPS и Q кол-ы (разделить $e_F$ и $e_Q$ нельзя; при упоре в лимиты ЭОВ+ частоты падают, мин. модель этого не учитывает.